











## 人工智能在猎豹内容产品的应用





闵可锐













## News Republic介绍

#### 面向海外的个性化内容推荐系统

- 数千正版媒体源(BBC, CNN, AP...)
- 数千万的下载安装量
- Google Play新闻杂志类Top 10







## News Republic介绍

每日新增超过10万篇内容

- 分词
- 词性分析
- 命名实体分析
- 提取关键词
- 情感分析
- · . STEPHENDERA IN











全球互联网技术大会

球互联网技术大会 11

全现互联网技术大会

为何需要语义分析

通过对符号字符串的解析,回答一篇文章在讲什么(Meaning),寻找与之相关的文章和潜在感兴趣的用户

理解文章 ⇒ 理解用户

全球互联网度水大会量扩展

金属石机网络水火岩

#### 拿美国联网技术大会 [H][[]

#### 全球互联网技术大会

#### 全球互联问技术大会

#### 为何需要语义分析


传统基于关键词理解: TF\*IDF, Okapi BM25

二义性: 从词语到句子, 从语法到语义

SEEMBOARD HILL

全场互联的技术大会

全球互联网络木大会 11









#### 全线互联网支术大会 [H][[]

#### 全球互联网技术大会

#### 全球互联问技术大会

#### 为何需要语义分析

传统基于关键词理解: TF\*IDF, Okapi BM25

二义性: 从词语到句子, 从语法到语义

全球互联网技术大会【拼】

**郑**夏联问技术大会

Time Flies Like
An Arrow
A Banana

全以互联网技术大会【计算】

Time: 时间/计时/时代周刊? Flies: 飞行/苍蝇? Like: 像/喜欢?

全球互联网技术大会





# 向量表示

#### 从词向量到文章向量

- 词向量:  $w \in \mathbb{R}^d, w \in V$
- 文章向量:  $c\in\mathbb{R}^D, c\in\mathcal{D}$

#### BOW表达

•  $c = \sum_i w_i$ ,丢失词序信息

#### 简单拼接

- $c = \operatorname{concat}(w_1 w_2 \cdots w_n), D = dn$
- 保留词序,向量空间大小不定

全球互联网技术大会计划

#### 全球互联网络林大会

全球互联问题术大会

#### 向量表示目标

映射为固定空间大小,方便使用

对词序敏感

能够 无标注 数据进行训练



全球互联网技术大会

EREKORALE HIL

全球互联网皮术大会

全项互联网度术大会

全球互联网技术大会【扩展

金成草族网络水大会 【拼】

全以互以同技术大会【扩展

全块互联网技术大会

全项互联网度本大会

全球互联网技术大会






#### 全球互联网支术大会【针】

#### 向量表示目标

映射为固定空间大小,方便使用 对词序敏感

**⇒** Recurrent Neural Network

$$h_t = f(h_{t-1}, x_t).$$



全球互联网技术大会

全球互联网络水大会 [4]

全球互联网络术人

全球互联网技术大会

全球互联网技术大会

全球互联网技术大会【光】


全球互联网度术大会

全球与联网技术大会

全球互联网技术大会

#### GRU

实际我们采用 Gated Recurrent Unit 进行实现



Chung, Junyoung, etc. "Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling", 2014.

## 无标注训练

映射为固定空间大小,方便使用 对词序敏感

能够 无标注 数据进行训练

Title: Microsoft released two brand-new laptops this

week, both killer Apple rivals

Date: 2017-06-17

Publisher: Business Insider

Content: This week, Microsoft released not one, but two new laptops.

First, you've got the Surface Laptop, an all-new device that's aimed at students. It also serves as the showcase device for Windows 10 S...

#### 金钱是我刚这样太全日间

#### 无标注训练

采用 Gated Recurrent Unit 实现 Encoder-Decoder 模型

输入: 新闻内容  $(x_1 \cdots x_n)$ 

输出:新闻标题  $(t_1 \cdots t_l)$ 

 $\operatorname{Encoder}(x_1\cdots x_n) o h_n \in \mathbb{R}^D, \ \operatorname{Decoder}(h_n) o t_1\cdots t_l.$ 

 $h_n$ 作为我们的语义向量(Why?) 经过实验,我们采用512维向量(D=512)训练结果





## 一些例子

#### Verizon Among Leading Bidders for Yahoo's Core Business: Bloomberg

- 1. Verizon Is Said to Be Near a Deal to Acquire Yahoo
- 2. UPDATE 1-Yahoo to be named Altaba, Mayer to leave board after Verizon deal
- 3. Verizon Communications : Yahoo's Marissa Mayer to resign from board after Verizon deal closes

#### SWAT team called to standoff incident in College Park

- 1. Woman shot in car near East Nashville apartments
- 2. Uber Driver Strikes Man 'Clearly Outside of Crosswalk:' San Jose Police Related
- 3. Man shot after confronting another driver over tailgating

#### 全等基本网络水大会 计打印

#### 全球互联网波术大会

#### 全球互联网络水大会

## 效率优化

全球互联网技术大会

全球互联网技术大会

对于任意两个语义向量距离度量

全球巨铁网技术大会【针】

全球互联网技术大会

$$\|h_i - h_j\|_2^2 = \sum_{k=1}^D (h_{ik} - h_{jk})^2$$

STATEMENT OF THE STATEM

上千次浮点运算.

**明显以同臣术大会【H**】)

全球互联网技术大会【针】

关注近邻查找而不是向量本身.

$$h^* = \mathcal{Q}(h_q) = \min_{h \in \mathcal{H}} \|h - h_q\|_2$$

全项互联网度本大会







## 全球互联网支术大会计划


#### 全球互联网技术大会

#### 全界互联网络水大会【片】

#### 近似解方案

#### **KD-Tree**

- 划分空间索引,搜索剪枝
- 精确查找时间复杂度:  $O(\log n) \to O(n)$
- 近似查找时间复杂度:  $O\left(\frac{1}{\epsilon^D}\log n\right)$
- 维数灾难



全球互联网技术大会

全球互联网技术大会

全项与联网技术大会

## 近似解方案

#### **Locality-sensitive Hashing**

对任意 $p,q\in\mathcal{M}$ ,均匀采样 $h\in\mathcal{F}$ 满足

- 如 $d(p,q) \leq R$ ,  $\mathbb{P}(h(p) = h(q)) \geq P$ ;
- 如d(p,q)>cR,  $\mathbb{P}(h(p)=h(q))\leq P-\epsilon$ .

存在 $\mathcal{F}$ , $\rho < 1/c$ ,使得

- 近似查找时间复杂度:  $O(Dn^{\rho})$
- 索引时间复杂度:  $O(Dn^{1+\rho})$

## **Learning to Hash**

LSH所采用的数据划分方式与具体数据无关(data-independent)对于具体数据集,可以根据其分布得到更好的划分

#### 目标:

学习映射f,对于 $h_i \in \mathcal{H}$ ,对应的语义指纹 $b_i = f(h_i)$ 满足:

- 二值化:  $b_i \in \{-1,1\}^d$ ,
- 近似保距: orall i,j Hamming $(b_i,b_j)pprox c\cdot \|h_i-h_j\|_2$

## 全球互联网技术大会

## **Learning to Hash**

 $f: \mathbb{R}^D \mapsto \mathbb{R}^d$ .

e.g.  $[3.16, 1.05, \cdots, -1.37] \mapsto 101101.$ 

#### 优势:

- 时间:相似度比较由浮点运算变为整数XOR运算
- 空间: 由D个实数变为了 $\lceil d/32 
  ceil$ 个int32整数

## **DeepBit**

DeepBit采用深度学习建模 $f(\cdot, W)$ , W为网络参数:

$$y_i = f(h_i, W), b_i = \text{sign}(y_i).$$

对于一个Mini-batch,采用如下的损失函数:

$$Loss = L_{quant} + \alpha L_{even}$$

- $L_{\mathrm{quant}} = \|y_i b_i\|_2$
- $L_{\mathrm{even}} = \sum_{k} \left( \sum_{i \in \mathcal{B}} b_{ik} \right)^2$

Kevin Lin, etc. Learning Compact Binary Descriptors with Unsupervised Deep Neural Networks, CVPR 2016.

#### **DeepBit**

#### DeepBit采用深度学习建模 $f(\cdot,W)$ , W为网络参数:

$$y_i = f(h_i, W), b_i = \text{sign}(y_i).$$

```
Algorithm 1: DeepBit
 Input: Training set X = [x_1, x_2, ..., x_n]
 Output: A set of non-linear projection parameters W
 Step 1 (Initialization):
 Initialize W with pre-trained weights from ImageNet;
 Step 2 (Optimization):
 while iter < max iter do
    Fix W update b_n using (1);
    while iter1 < max\_iter1 do
        Fix b_n update W by minimizing the sum of (5)
        and (6);
    Fix W update b_n using (1);
    while iter2 < max\_iter2 do
        Fix b_n update W using (8);
 return W:
```

# 全线互联网技术大会计划

## 全球互联网技术大会

## 全球互联网技术大会

#### **DeepBit**

上述算法采用的是 Alternating Minimization 的方式,交互更新W与 $b_i$ :

- 收敛速度较慢
- 更容易陷入次优(sub-optimal)的局部最优解

为什么不采用 端到端 的方式进行优化?

## 端到端优化

```
def train(h, W, alpha):
    # forward step
    y = f(h, W)
    b = sign(y)

L = L_quant(y, b) + alpha*L_even(b)
    dW = backprop(L)

W = W - lr*dW # SGD step
```

是否可行?









```
全球互联网技术大会
```



## No!

```
全球互联网技术大会
```

```
战马跃列技术大会 【打】
```






















全级互联网技术大会

导数几乎处处为零!

在端到端更新中,没有可被反向传播的梯度

全球互联网技术大会


全国互联网技术大会

## 近似Sign函数

#### 可以采用soft-sign函数对sign函数进行近似

$$\operatorname{soft-sign}(x,\epsilon) = \frac{x}{\epsilon + |x|},$$

$$\operatorname{sign}(x) = \lim_{\epsilon o 0} \operatorname{soft-sign}(x,\epsilon).$$



## 近似准确率

 $\operatorname{sign}(x) = \lim_{\epsilon \to 0} \operatorname{soft-sign}(x, \epsilon).$ 


对于x,近似程度取决于 $\epsilon/|x|$ 的值.

为避免由于y=f(x,W)过小带来的,引入倒数正则项:

$$L_{ ext{inverse}}^2 = \left\|rac{1}{y}
ight\|_2^2 = \sum_{i=1}^d rac{1}{y_i^2}.$$

#### 非均匀采样

近似保距: orall i,j Hamming $(b_i,b_j)pprox c\cdot \|h_i-h_j\|_2$ 



$$L_{\text{dist}} = L_{\text{KNN}} + L_{\text{rand}}.$$

 $L_{ ext{KNN}}: K$ 近邻近似误差, $L_{ ext{rand}}$ 随机点近似误差.

# 全球互联网技术大会【HII】





全球互联网络木大会【针】

全球互联网技术大会

全球互联网技术大会

#### Put together

```
全球互联网技术大会【样】
```

```
def train(h, W, alpha):
    # forward step
    y = f(h, W)
    b = soft-sign(y) # approximate sign function

L = L_dist(b, h) + alpha*L_inverse(y)
    dW = backprop(L)


W = W - lr*dW # SGD step
```

全球互联网技术大会





# 定义 f 网络



简单三层网络,总参数~1.6MB

#### 实验结果

Batch-size=32完成50k次SGD迭代

固定 $\epsilon=0.01$ ,99%的 $b_{ij}\in[-1,-0.99]\cup[0.99,1.0]$ .




金融互联网及水大金目引力



全级互联网技术大会【针】









## 全球互联网技术大会

## 语义指纹碰撞

#### 枪击/谋杀,被判处死刑

- DA's office to seek death penalty in case against man accused of killing Kayla Gomez-Orozco
- Whitehall shooting victim shot himself, lied to police about drive-by
- 3. Jury continues to mull attempted-murder charge in Clinton Township shooting
- 4. Inmate bites caseworker, punches guards at Nebraska prison

# 全球互联网技术大会【拼】

#### 全球互联网技术大会

## 语义指纹碰撞

#### 朝鲜导弹试验

- 1. US see increased activity by Chinese bomber aircraft
- N. Korea Warns of 'Super-Mighty Preemptive Strike' as U.S. Plans Next Move
- 3. Donald Trump: If China wanted to end North Korean aggression, it could
- 4. U.S. sets up missile defence system in South Korea as North flexes muscles







全球互联网技术大会【划】

全球互联网技术大会

全球互联网技术大会

#### 深度学习图像理解应用

全球互联网技术大会【针】

金球草联网技术大会【打

- 性感/色情图片识别
- LOGO/文本识别
- 不适图片识别

全球互联问技术大会

- 马赛克图片识别
- . . .
  - 全球互联网技术大会

全球互联网度术大会

全球互联网皮术大会







#### 生成马赛克图片
































## 识别出的文字图片





sadomizzo le aspettative schiavizzo questa folla che elettrizzo con ste rime, perso in questa storia di qui non so le rime, verso sangue incandescente che brucia le puntine.



















